

به نام خدا



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و
کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین ۱

نام و نام خانوادگی: امیر پارسا موبد

شماره دانشجویی: ۸۱۰۱۰۰۲۷۱

آبان ماه ۱۴۰۴

فهرست

4.....	پاسخ سوال اول
4.....	پاسخ بخش اول
7.....	پاسخ بخش دوم
8.....	پاسخ سوال دوم
8.....	پاسخ بخش اول
8.....	پاسخ بخش دوم
9.....	پاسخ بخش سوم
9.....	پاسخ سوال سوم
10.....	پاسخ سوال چهارم
10.....	پاسخ بخش اول
11.....	پاسخ بخش دوم
12.....	پاسخ بخش سوم
13.....	پاسخ بخش چهارم
13.....	پاسخ بخش پنجم
14.....	پاسخ سوال پنجم
14.....	پاسخ بخش اول
15.....	پاسخ بخش دوم
15.....	پاسخ بخش سوم
16.....	پاسخ بخش چهارم
17.....	پاسخ بخش پنجم

الف) مدل PIV

فرمول کلی:

$$\sum_{w \in q \cap d} \underbrace{(1 + \ln(1 + \ln(c(w, d))))}_{\text{TF weighting}} \cdot \underbrace{\frac{N+1}{df(w) \cdot d}}_{\text{IDF weighting}} \cdot \underbrace{\frac{c(w, q) \cdot d}{(1-s) + s \cdot \frac{|d|}{avdl}}}_{\text{Length Normalization}}$$

1) TF weighting

$$(1 + \ln(1 + \ln(c(w, d))))$$

تنها بخشی از فرمول است که به $c(w, d)$ (تعداد تکرار واژه در سند) وابسته است، و مقدار آن با افزایش TF افزایش می‌یابد. و دو بار لگاریتم گرفته شده، که تاثیر تکرارها را به تدریج کم کند (فرق ۵۰ تکرار با ۵۱ تکرار کمتر از فرق ۱ تکرار و ۲ تکرار باشد).

۲) IDF weighting

$$\frac{N+1}{df(w) \cdot d}$$

کسر تعداد کل اسنادها بر روی تعداد اسنادی که یک کلمه در آن حضور دارد است که در نتیجه هر حضور متداول تر باشد، تاثیر کمتری می‌گذارد.

۳) Length Normalization

$$\frac{c(w, q) \cdot d}{\frac{|d|}{avdl} \cdot s + (s - 1)}$$

در این بخش هم هر چقدر طول سند بیشتر از میانگین باشد مخرج کسر بزرگتر می‌شود که در نهایت باعث کاهش مقدار عبارت می‌شود، پس برای جریمه کردن طول سند است.

ب) مدل BM25

فرمول کلی:

$$\sum_{w \in q} \underbrace{\ln \left(\frac{N - df(w) + 0.5}{df(w) + 0.5} \right)}_{\text{IDF weighting}} \cdot \underbrace{\frac{(k_1 + 1)c(w, d)}{k_1 \left((1 - b) + b \frac{|d|}{avdl} \right) + c(w, d)}}_{\text{TF weighting + Length Normalization}} \cdot \underbrace{\frac{(k_3 + 1)c(w, q)}{k_3 + c(w, q)}}_{\text{Query Term Weight}}$$

1) TF weighting و Length Normalization

$$\frac{c(w, d)(k_1 + 1)}{k_1 \left((1 - b) + b \frac{|d|}{avdl} \right) + c(w, d)}$$

این تنها بخشی از فرمول است که به تعداد تکرار واژه در سند وابسته است.

افزایش TF باعث بزرگتر شدن مقدار کسر می‌شود، اما به‌خاطر وجود $c(w, d)$ در هم صورت هم مخرج (در صورت ضرب در k_1 و در مخرج به علاوه) اثر تکرارها به‌مرور کمتر می‌شود. همچنین در k_1 مخرج عبارت Length Normalization هم ضرب شده که در صورتی که $b > 0$ باشد طول سندهای بلندتر از میانگین را جریمه می‌کند.

۲) IDF weighting

$$\ln \left(\frac{N - df(w) + 0.5}{df(w) + 0.5} \right)$$

این بخش برای هر کلمه هرچقدر در سندهایی بیشتری آمده باشد به ترتیب، صورت کاهش می‌یابد (عبارت $df(w)$ – در فرمول) و مخرج افزایش می‌یابد (عبارت $df(w)$ + در فرمول)، پس کوچکتر می‌شود و تاثیر کلمات متداول را در نمره کاهش می‌دهد.

۳) Query term weight

$$\frac{(k_3 + 1)c(w, q)}{k_3 + c(w, q)}$$

در این مدل می‌بینیم که برای تکرار کلمات در کوئری هم یک عبارت کسری داریم که حد آن در بینهایت $k_3 + 1$ است. و باعث می‌شود تکرارهای بعدی کلمه در پرسش تاثیر کمتری داشته باشد.

ج) مدل PL2

فرمول کلی:

:PL2

$$\sum_{c(w,q) \cdot \ln(1+\epsilon) \in q \cap d} \left(\frac{tfn_w^d}{tfn_w^d + 1} \cdot \log_2(tfn_w^d \cdot \lambda_w^d) + \log_2 e \cdot \left(\frac{1}{\lambda_w} - tfn_w^d \right) + 0.5 \right. \\ \left. \cdot \log_2(2\pi \cdot tfn_w^d) \right)$$

Where:

$$tfn_w^d = c(w, d) \cdot \log_2 \left(1 + c \cdot \frac{avdl}{|d|} \right)$$

$$\lambda_w^d = \frac{N}{c(w, C)}$$

TF weighting (۱)

$$tfn_w^d = c(w, d) \cdot \log_2 \left(1 + c \cdot \frac{avdl}{|d|} \right)$$

هسته‌ی وزن‌دهی این مدل همین tfn است. این عبارت مستقیماً به $c(w, d)$ وابسته است، بنابراین تنها بخشی است که رفتار TF را کنترل می‌کند. ضریب لگاریتمی باعث می‌شود شدت تأثیر TF برای مقادیر بزرگ به تدریج کاهش یابد.

IDF weighting (۲)

$$\lambda_w^d = \frac{N}{c(w, C)}$$

این مقدار به فراوانی ترم در کل مجموعه $c(w, C)$ وابسته است. اگر یک ترم در کل مجموعه کمتر دیده شود (کمیا‌تر باشد)، λ بزرگ‌تر و وزن آن بیشتر می‌شود. بنابراین این بخش نقش IDF را برعهده دارد، حتی اگر شکلش به صورت IDF کلاسیک نباشد.

Length Normalization (۳)

در PL2 نرمال سازی طول داخل همان tfn اتفاق می افتد:

$$\log_2 \left(1 + c \cdot \frac{avdl}{|d|} \right)$$

این عبارت تنها بخشی است که به طول سند وابسته است.
اگر سند بلند باشد ($avdl < |d|$) مقدار این عبارت کوچک می شود و TF نرمال شده کاهش می یابد؛
پس سندهای بلند جریمه و سندهای کوتاه تقویت می شوند.
در نتیجه این بخش دقیقاً نقش Length Normalization را ایفا می کند.

پاسخ بخش دوم

در مدل PL2 تنها جایی که پارامتر تنظیمی c ظاهر می شود، در تعریف TF نرمال شده است:

$$tfn_w^d = c(w, d) \cdot \log_2 \left(1 + c \cdot \frac{avdl}{|d|} \right)$$

(c) پارامتر c فقط روی بخش Length Normalization اثر می گذارد.

- این پارامتر تعیین می کند طول سند چه قدر روی وزن نهایی اثر بگذارد.
- اگر مقدار c بزرگ شود، عبارت داخل لگاریتم بزرگ تر می شود و حساسیت مدل نسبت به طول سند شدیدتر می شود.
- اگر مقدار c کوچک شود، عبارت لگاریتمی کوچک تر شده و اثر طول سند تقریباً از بین می رود.

تاثیر افزایش آن را به صورت شهودی می توان به این صورت بررسی کرد:

اگر سند بلندتر از میانگین باشد $\frac{avdl}{|d|}$ کوچکتر می شود در نتیجه:

- مقدار لگاریتم کاهش می یابد
- در نتیجه مقدار tfn کوچک تر می شود
- سندهای بلند بیشتر جریمه می شوند

اگر سند کوتاه تر از میانگین باشد:

- مقدار لگاریتم بزرگ تر می شود
- وزن TF افزایش می یابد

- سندهای کوتاه تقویت می‌شوند

در نتیجه به صورت حدودی می‌فهمیم پارامتر c فقط روی Length Normalization اثر دارد (و نه روی TF خام و نه روی IDF)

برای اثبات ریاضی کافی است نسبت به c از tfn مشتق بگیریم که نتیجه می‌دهد فقط بر روی Length Normalization تاثیر می‌گذارد.

$$\frac{\partial \text{tfn}_w^d}{\partial c} = c(w, d) \cdot \frac{1}{\ln 2} \cdot \frac{\text{avdl}/|d|}{1 + c \cdot \text{avdl}/|d|}$$

پاسخ سوال دوم

پاسخ بخش اول

برای محاسبه وزن‌های مدل رابرتسون-اسپارک جونز (RSJ) به دو پارامتر نیاز داریم:

- $p_i = P(A_i = 1 | R = 1)$ احتمال این‌که ترم i در یک سند مرتبط ظاهر شود.

- $q_i = P(A_i = 1 | R = 0)$ احتمال این‌که ترم i در یک سند نامرتب ظاهر شود.

برای تخمین این احتمالات باید مجموعه‌ای از اسناد داوری شده داشته باشیم تا مشخص شود کدام اسناد برای کوئری مرتبط بوده‌اند و کدام نامرتب. سپس برای هر واژه تعداد اسناد مرتبطی که آن واژه را دارند (r_i) و تعداد اسناد نامرتب

که واژه در آن‌ها دیده می‌شود (n_i) را می‌شماریم. مقدار p_i را می‌توان با هموارسازی به صورت $p_i \approx \frac{r_i + 0.5}{R + 1}$ و q_i را به صورت $q_i \approx \frac{n_i + 0.5}{N + 1}$ تخمین زد که در آن R تعداد اسناد مرتبط و N تعداد اسناد نامرتب است.

اگر دسترسی به داورهای ربط نداشته باشیم (مثلاً در جستجوی بدون برچسب)، معمولاً فرض ساده‌ای به کار می‌رود: p_i را ثابت نسبتاً بزرگی در نظر می‌گیرند (برای مثال 0.5 به این معنی که واژه در حدود نیمی از اسناد مرتبط وجود دارد) و q_i را با نسبت فراوانی واژه در کل مجموعه

تخمین می‌زنیم، یعنی $q_i \approx \frac{n_i}{N}$. این ایده شبیه روش Croft & Harper است که در آن p_i ثابت و q_i متناسب با document frequency واژه است.

پاسخ بخش دوم

اگر فرض کنیم $p_i \approx 0.5$ و $q_i \approx \frac{n_i}{N}$ ، وزن واژه در مدل RSJ به صورت زیر خواهد بود:

$$\omega_i = \log \frac{p_i(1-q_i)}{q_i(1-p_i)} = \log \frac{(\frac{n_i}{N}-1).0.5}{\frac{n_i}{N}.0.5} = \log \frac{N-n_i}{n_i}$$

در این فرمول N تعداد کل اسناد نامرتب (یا به طور تقریبی کل اسناد) و n_i تعداد اسنادی است که واژه‌ی i در آن‌ها ظاهر شده است. این شکل ساده‌شده‌ای از وزن RSJ است که با document frequency واژه رابطه مستقیم دارد.

پاسخ بخش سوم

اگر N را ثابت فرض کنیم و n_i (فراوانی سندی واژه) افزایش یابد، نسبت $\frac{N-n_i}{n_i}$ کاهش می‌یابد و در نتیجه مقدار ω_i کوچک‌تر می‌شود. بنابراین هر چه واژه در اسناد بیشتری ظاهر شود، وزن آن در مدل RSJ کاهش می‌یابد. این دقیقاً رفتار بخش IDF در مدل‌های وزن‌دهی دیگر (مثل BM25) را منعکس می‌کند: واژه‌های کمیاب وزن بیشتری دارند و واژه‌های عمومی وزن کمتری می‌گیرند.

پاسخ سوال سوم

$$\sum_{w \in q} \ln \underbrace{\left(\frac{N - df(w) + 0.5}{df(w) + 0.5} \right)}_{\text{IDF weighting}} \cdot \underbrace{\frac{(k_1 + 1)c(w, d)}{k_1 \left((1 - b) + b \frac{|d|}{avdl} \right) + c(w, d)}}_{\text{TF weighting + Length Normalization}} \cdot \underbrace{\frac{(k_3 + 1)c(w, q)}{k_3 + c(w, q)}}_{\text{Query Term Weight}}$$


شکل ۳: فرمول BM25

۱. با توجه به عبارت کافی است b را مساوی ۰ قرار دهیم. تا عبارت زیر ۱ شود و تغییر طول سند هیچ کاری انجام ندهد.


$$\left((1 - b) + b \frac{|d|}{avdl} \right)$$

۲. در این صورت $\frac{|d|}{avdl} = 1$ و عبارت بالا برابر با $1 - b + b = 1$ می‌شود. پس نه b تاثیری نخواهد داشت.

۳. اگر طول سند بیشتر از طول میانگین باشد شیب منفی، و اگر کمتر باشد شیب مثبت است. این یکنی در حالتی که طول سند بیشتر از میانگین است (سند باید جریمه شود) با افزایش b بیشتر جریمه می‌شود. و وقتی طول سند کمتر از میانگین است با افزایش b پست می‌شود.



۴. از آنجایی که k_1 در عبارتی که b دارد ضرب می‌شود با افزایش آن تاثیر b هم بیشتر می‌شود و بیشترین تاثیر را همانطور که می‌توان مشاهده کرد $k_1 = 3$ دارد.





پاسخ سوال چهارم

پاسخ بخش اول

در ابتدا رتبه‌بندی اولیه را در تصویر زیر می‌بینید که به درستی رتبه اول را به داکيومنتی که بیشتر مرتبط با Machine Learning است داده.

اما چیزی که به راحتی می‌توان مشاهده کرد طول کمتر داکيومنت دوم است در حالی که تمام کلمات کوثری را دارا است. پس برای به اشتباه انداختن الگوریتم کاری که به ذهن می‌رسد جریمه کردن طول داکيومنت است، که همانطور که مشاهده می‌کنید موفقیت آمیز نیز بوده و با افزایش length normalization parameter داکيومنت دوم به رتبه اول می‌رود.



شکل ۴.۱.۲ نتیجه رتبه‌بندی متفاوت با پارامترهای متفاوت



شکل ۴.۱.۱ نتیجه سمپل ابتدایی سمپل ۱

پ.ن: پارامترها در تصویر مشخص است و میانگین طول نیز ۲۳ و طول سندی که از لحاظ نتیجه مورد انتظار انسان(من) سند نزدیکتر است، سند شماره ۱ با طول ۲۶ است و سند دو که بخاطر طول کمتر از میانگین boost شده‌است طول ۲۰ دارد.

پاسخ بخش دوم

در این دو سند با توجه به طول برابر، می‌توان تشخیص داد که تغییر را به عوض کردن وزن Term frequency saturation parameter باید بدست آورد. همچنان چیزی که از منظر انسان مشخص است این است که داکيومنت مرتبط تر سند شماره ۱ است.

بدین ترتیب دنبال تفاوت‌ات سند شماره دو می‌رویم، تا پارامتری برای خراب کردن رتبه‌بندی بدست آوریم. در سند شماره ۲ توزیع کلمات کوئری به ترتیب ۳، ۴، ۱ است و این مقدار برای سند ۱ به ترتیب ۲، ۲، ۳ است. به این ترتیب افزایش k_1 اهمیت تکرار افزایش می‌یابد به این ترتیب سند شماره ۲ با وجود اینکه فقط یکبار کلمه‌ی algorithm آمده چون در مجموع کلمات بیشتری از کوئری در متن خود دارد به رتبه یک می‌رود. این را می‌توانید در دو شکل پایین مشاهده کنید.



شکل ۴.۲.۲: نتیجه تغییر پارامتر k_1

شکل ۴.۲.۱: نتیجه سمپل ۲ که سند ۱ به درستی رتبه ۱ شده است.

پاسخ بخش سوم

سمپل ۳

در این مثال به نوعی ترتیب مهم است (تهران به کیش) که BM25 جایی ترتیب را دخالت نمی‌دهد، مگر اینکه تعریف ترم‌ها را تغییر دهیم.

در اصل مشکل فراتر از ترتیب است. در این کوئری باید مفهوم درخواست درک شود که دنبال مبدا تهران و مقصد کیش است و این مفهوم به هر ترتیبی در سندها بیاید می‌تواند یک سند مرتبط باشد.

سمپل ۴

سندی که به تکرار کلمه "آیفون" آمده رتبه بهتری می‌گیرد، که این هم به نوعی نیاز به ارزیابی مفهومی دارد. ضمناً پرسش نیز از کلیدواژه "جدید" استفاده کرده، که احتمالاً معادل همان آیفون ۱۵ است. که این اطلاعات چیزی خارج از اطلاعاتی است که BM25 برای رتبه‌بندی استفاده می‌کند (اینکه آیفون ۱۵ همان آیفون جدیدی است که کاربر دنبال آن می‌گردد). و هرچند بتوان spam را تغییر داد همچنان مشکل در پیدا کردن سند شماره ۱ وجود خواهد داشت.

سمپل ۵

در این سمپل دو کلمه با املاهای یکسان که معنی متفاوتی دارند، در پرسشی که کلمات کافی برای مشخص کردن **کانتکست** ندارد، خروجی را نامطمئن کرده است. در این پرسش گرچه حتی انسان هم نمی‌تواند با اطمینان بگوید کاربر دنبال چیست، اما بر اساس عمومیت گوشی iPhone، به علاوه کلمه "جدید" می‌تواند تشخیص بدهد که کاربر احتمالاً دنبال آیفون در باز کن جدید نیست و برایش اهمیت ندارد.

پس مشکل BM25 در این سمپل را می‌توان عدم استدلال مدل و ابهام کوئری کاربر بیان کرد.

سمپل ۶

در این مثال، کلمه‌ای هم معنی با کلمات پرسش در سند آمده که باعث می‌شود تعداد حضور term در سند، مقدار نامناسبی باشد، و باید از روش دیگری مانند جایگزین کردن با کلمه هم‌معنی استفاده کرد.

پاسخ بخش چهارم

یک ایده می‌تواند فقط استفاده از تایتل باشد، چون به نوعی این ایندکسینگ آمد تا جایگزین تایتل manual شود و خب وقتی سند تایتل دارد خود تایتل ارجحیت دارد. در این حالت تنها چیزی که باید جلوییش را گرفت spam بودن یک سند است، که بنظر مسئله‌ای جداگانه است و برای هر سند به صورت منحصر تعریف می‌شود که آیا متن مربوط به تایتل هست یا نه. و این مسئله نسبتاً خوش تعریف است و ضمناً روی spam checking تحقیقات بسیاری انجام شده است.

ایده دوم این است که از تجمیع نمره تایتل و سند استفاده کنیم. ولی برای اهمیت دادن به تایتل از میانگین وزن دار استفاده کنیم و وزن بیشتری به تایتل بدهیم. نسخه رسمی‌تر همین ایده در قالب BM25F مطرح شده که عملاً یک نسخه چندفیلدی از BM25 است؛ یعنی برای هر فیلد یک وزن و یک نرمال‌سازی جدا دارد و در نهایت آن‌ها را ادغام می‌کند. ولی حتی اگر از BM25F هم استفاده نکنیم، همین ایده وزن‌دهی جداگانه به تایتل و متن می‌تواند در عمل نتیجه معقول‌تری بدهد.

ایده نهایی من هم این است که متن تایتل و متن سند را (قبل از محاسبه نمره) تجمیع کنیم و عادی (بدون تایتل) بررسی کنیم.


پاسخ بخش پنجم

خیر؛ اینکه تور، تور مالزی باشد مهمتر است. در این مثال BM25 به خاطر تکرار واژه‌های عمومی مثل «پرواز» امتیاز بیشتری به سند دوم داده، درحالی‌که «مالزی» واژه‌ی اصلی کوئری است و موضوع را تعیین می‌کند. بنابراین نمی‌توان انتظار داشت صرفاً بالا بودن TF یا حتی IDF یک واژه مثل «پرواز» باعث رتبه‌بندی درست شود؛ اهمیت معنایی واژه‌ها همیشه از IDF تعیین نمی‌شود و BM25 در چنین نمونه‌هایی ممکن است اشتباه کند.

پاسخ سوال پنجم

پاسخ بخش اول

در شکل زیر می‌بینید که چون MRR فقط اولین سند مرتبط برایش مهم است رنکینگ دوم نمره بهتری در آن دارد اما چون گزینه‌های بعدی را همه را اشتباه گفته، همانطور که مشاهده می‌کنید بقیه نمره‌هایش بدتر است.




شکل ۵.۱.۱: رتبه‌بندی ۲ در معیار MRR بهتر ولی در باقی معیارها بدتر است.

پاسخ بخش دوم

MRR زمانی معیار مفیدی است که کاربر «یک جواب کافی» بخواهد، مثلاً در کوئری‌های هدایت‌گر (navigational) یا known-item search که هدف پیدا کردن یک صفحه خاص است (مثل homepage یک سایت) یا در سیستم پرسش‌وپاسخ که اولین جواب درست مهم است و بقیه جواب‌ها اهمیت کمتری دارند.

پاسخ بخش سوم

بله؛ این زمانی رخ می‌دهد که رتبه‌بندی اول سند نامرتب را بهتر تشخیص داده اما رتبه‌بندی آنها خوب نیست و یک سند با rel بالا در پایین قرار داده. مشابه شکل پایین که می‌بینید رتبه‌بندی شماره ۱ تمام سندهای مرتبط را بازیابی کرده. در سوی دیگر رتبه‌بندی ۲ یک سند مرتبط را بازیابی نکرده اما بقیه ترتیبش درست است.




پاسخ بخش چهارم

همانطور که در بخش قبل هم اشاره شد، در NDCG@5 که اگر به نحوه محاسبه NDCG@5 در شکل ۵.۳.۱ دقت کنید متوجه این می‌شوید که rel تقسیم بر لگاریتم جایگاه جمع زده شده‌است که نشان دهنده تاثیر رتبه‌بندی است.

پاسخ بخش پنجم

بله؛ همانطور که در شکل ۵.۵.۱ می‌بینید امکان دارد P@5 دو رتبه‌بندی یکی باشد اما AP آنها یکی نباشد. AP برای سندهای بازبایی شده میانگین $P@i$ هایی است که در i یک سند مرتبط قرار دارد. پس می‌توان گفت به طور غیر مستقیم مرتبط‌اند. مثلاً نمی‌توان گفت اگر دو بازبایی را مقایسه کنیم که یکی ریکال بالاتری از دیگری داشته باشد لزوماً AP بالاتره هم دارد، اما اگر در یک بازبایی به خصوص جای یک سند نامرتب یک سند مرتبط را بازبایی می‌کردیم احتمال داشت AP افزایش یابد.



شکل ۵.۵.۱: دو رتبه‌بندی با R@5 و P@5 برابر و AP متفاوت